Detekcja makroskładników jedzenia na podstawie zdjęcia: przegląd rozwiązań, modeli i stanu badań

Michał Dąbrowski Dominik Zabielski

PROseminarium — research wstępny

październik 2026

Streszczenie

Dokument stanowi przegląd aktualnego stanu wiedzy i narzędzi w obszarze automatycznego szacowania wartości odżywczych (kalorie oraz makroskładniki: białko, tłuszcz, węglowodany) na podstawie fotografii posiłku. Omówiono główne sformułowania problemu, kluczowe zbiory danych (w szczególności Nutrition5k), klasyczne i współczesne architekturę (CNN, Vision Transformer, multimodalne VLM), wybrane modele dostępne na Hugging Face oraz rozwiązania komercyjne (aplikacje mobilne). Na końcu wskazano praktyczne ścieżki realizacji projektu proseminaryjnego.

Spis treści

1 Wprowadzenie i motywacja **3**

2 Sformułowanie problemu **3**
2.1 Podejście A — klasyfikacja + baza odżywcza . . . 3
2.2 Podejście B — bezpośrednia regresja makro . . . 3
2.3 Podejście C — multimodalne VLM + RAG / baza . . . 3

3 Kluczowe zbiory danych **4**
3.1 Nutrition5k (Google Research, CVPR 2021) . . . 4

4 Architektury i podejścia naukowe (stan 2024–2026) **4**
4.1 Baseline Nutrition5k . . . 4
4.2 CNN i Vision Transformers . . . 4
4.3 Segmentacja + open-vocabulary . . . 5
4.4 Depth-from-RGB . . . 5
4.5 Multimodalne LLM / VLM + RAG . . . 5

5 Modele na Hugging Face — przegląd praktyczny **5**
5.1 Estymacja kalorii / makro (priorytet tematyczny) . . . 5
5.2 Klasyfikacja potraw (baseline / pipeline A) . . . 6
5.3 Modele tekstowe / pomocnicze . . . 6
5.4 Jak szybko zacząć na HF . . . 6

6 Rozwiązania komercyjne i produktowe **6**

7 Metryki ewaluacji **6**

8 Wyzwania i ograniczenia **7**

9 Propozycja realizacji projektu (dla grupy) 7
9.1 MVP (realistyczny zakres proseminarium) 7
9.2 Rozszerzenia (jeśli zostanie czas) 7
9.3 Stack technologiczny (propozycja) 7

10 Podsumowanie 7

Wybrane źródła i linki 8

1 Wprowadzenie i motywacja

Ręczne logowanie posiłków w aplikacjach dietetycznych jest czasochłonne i podatne na błędy. Alternatywą jest *image-based dietary assessment*: system, który na podstawie zdjęcia talerza szacuje masę porcji oraz zawartość kalorii i makroskładników.

Problem jest trudny z kilku powodów:

- z jednego 2D zdjęcia nie da się jednoznacznie odtworzyć objętości (głębia, okluzja, perspektywa);
- potrawy są złożone (wiele składników, sosy, warstwy);
- ta sama klasa jedzenia ma bardzo różną gęstość kaloryczną (np. sałatka vs. orzechy);
- bazy żywieniowe różnią się między krajami (USDA, krajowe FCDB).

Mimo to dziedzina dynamicznie się rozwija: od klasycznej klasyfikacji Food-101, przez regresję makro na Nutrition5k (Google, CVPR 2021), po modele multimodalne (VLM) z dostępem do baz USDA / FNDDS.

2 Sformułowanie problemu

W praktyce stosowane są trzy główne pipeline'y.

2.1 Podejście A — klasyfikacja + baza odżywcza

1. Rozpoznaj klasę potrawy / składniki (klasyfikacja lub detekcja).
2. Oszacuj porcję (heurystyka, referencyjny obiekt, głębokość).
3. Zmapuj wynik do bazy (USDA FoodData Central, Open Food Facts itp.).

Zaleta: interpretowalność. Wada: błąd kumuluje się na każdym etapie; słaba generalizacja na dania mieszane.

2.2 Podejście B — bezpośrednia regresja makro

Sieć (CNN / ViT) dostaje obraz i przewiduje wektor

$$\hat{y} = (\text{kcal},\ m,\ \text{protein},\ \text{fat},\ \text{carbs}).$$

(odpowiednio: kalorie, masa, białko, tłuszcz, węglowodany). To dominujące podejście naukowe na Nutrition5k. Zaleta: prosty koniec-do-końca trening. Wada: słabsza interpretowalność; trudniej przenieść model na inną kuchnię / bazę.

2.3 Podejście C — multimodalne VLM + RAG / baza

Model wizyjno-językowy opisuje składniki i gramy, a wartości odżywcze pobierane są z autorytatywnej bazy (np. DietAI24 + FNDDS). Zaleta: szerszy zakres składników odżywczych, lepsza elastyczność. Wada: koszt inferencji, ryzyko halucynacji bez RAG.

Rekomendacja dla projektu: zacząć od B (regresja na Nutrition5k), opcjonalnie dodać A (klasyfikacja Food-101) jako baseline porównawczy; C traktować jako wariant zaawansowany / demonstracyjny.

3 Kluczowe zbiory danych

Tabela 1: Wybrane zbiory istotne dla tematu.

Zbiór	Skala	Co daje
Nutrition5k	∼5006 dań	RGB(+D), wideo, masa, kcal, makro, składniki (USDA)
Food-101	101 klas × 1000	klasyfikacja potraw (bez dokładnych makro)
FoodSeg103	segmentacja	maski składników (pomoc przy porcjach)
NutritionVerse	syntetyczne + real	multitask regresja makro
Open Food Facts	produkty opakowane	etykiety / kody kreskowe (nie talerz)

3.1 Nutrition5k (Google Research, CVPR 2021)

Najważniejszy benchmark do bezpośredniej estymacji makro:

- ∼5000 prawdziwych dań z kantyn Google;
- $>$ 250 składników, średnio ∼5,7 składnika na talerz;
- etykiety: całkowita masa, kalorie, tłuszcz, węglowodany, białko oraz rozbicie per-składnik;
- dla ∼3500 dań dostępne obrazy RGB-D z góry (Intel RealSense);
- oficjalny split train/test (∼90/10).

Źródło: https://github.com/google-research-datasets/Nutrition5k. Na Hugging Face istnieją przetworzone warianty, m.in. `ai5labsOfficial/nutrition5k`, `arunapb/nutrition5k-foodseg103`.

Uwaga praktyczna: pełny zbiór jest duży (∼180 GB). Do eksperymentów studenckich wystarczy subset klatek overhead RGB + metadane CSV.

4 Architektury i podejścia naukowe (stan 2024–2026)

4.1 Baseline Nutrition5k

Oryginalna praca Thames i in. (CVPR 2021) pokazała, że regresja z obrazu może przewyższać szacunki profesjonalnych dietetyków na tym zbiorze. Dodanie głębokości (RGB-D) poprawia estymację masy/porcji.

4.2 CNN i Vision Transformers

Benchmarki 2025 (m.in. analiza na Nutrition5k z różnymi FCDB) wskazują, że:

- **ResNet-101** dobrze radzi sobie z masą i energią;
- **ViT-B/16** często wygrywa na białku i węglowodanach;
- InceptionV3 (historyczny baseline) jest już wyraźnie słabszy.

Typowe błędy (MAPE, rząd wielkości): masa ∼20–23%, energia ∼26–29%, makro ∼30–50% — zależnie od curation danych. Korekta mas składników w etykietach mocno poprawia metryki (nawet 6–42%).

NutritionVerse-Direct (2024): ViT + wspólne warstwy FC + 5 głowic regresyjnych; istotna poprawa względem Inception-ResNet.

Swin Transformer + EfficientNet + FPN (Frontiers in Nutrition, 2024): Top-1 ∼79,5%, MAPE kalorii ∼14,7% na Nutrition5k.

Cross-ViT multi-scale (2026): raportowane MAE ∼28 kcal oraz ∼6/5/10 g dla białka/tłuszczu/węglowodanó (tylko RGB).

4.3 Segmentacja + open-vocabulary

Podejścia łączące segmentację jedzenia (oddzielenie tła) z Transformerem i/lub głębokością osiągają średnie PMAE rzędu ∼17% na Nutrition5k. Analizy attention pokazują, że tło bywa ważne dla kalorii/masy/węglowodanów, a mniej dla białka i tłuszczu.

4.4 Depth-from-RGB

Gdy nie ma czujnika głębi, stosuje się modele estymacji depth (np. Depth Anything) i dokłada kanał głębokości — przykład: NutriIngredientNet / DPF-Nutrition.

4.5 Multimodalne LLM / VLM + RAG

DietAI24 (Communications Medicine, 2025): MLLM + Retrieval-Augmented Generation z bazą FNDDS; szacuje dziesiątki składników odżywczych, nie tylko makro. Silnie redukuje MAE względem klasycznych CV baseline'ów na mieszanych daniach rzeczywistych.

Trend: *nie polegać na "pamięci" VLM co do kcal*, tylko rozpoznawać składniki/gramy i czytać bazę.

5 Modele na Hugging Face — przegląd praktyczny

Poniżej modele bezpośrednio przydatne do projektu (stan na październik 2026). Liczby downloadów zmieniają się szybko — ważniejsza jest jakość karty modelu i zgodność z Nutrition5k / makro.

5.1 Estymacja kalorii / makro (priorytet tematyczny)

Model (HF)	Typ	Komentarz
`opencal/opencal-base`	VLM (ONNX)	Fine-tune LFM2.5-VL-450M; JSON składników z gramami + kcal/makro (USDA); działa w przeglądarce (transformers.js / WebGPU).
`jc-builds/CalorieCLIP`	CLIP + regresja	MAE ∼51,4 kcal; lokalnie, <50 ms; tylko kalorie (nie pełne makro); lepszy od GPT-4o/Claude w ich teście.
`aman24012/nutrivision-omnigs`	CNN/hybryda	5 wyjść: cal, mass, fat, carb, prot; mean PMAE ∼13,5% na Nutrition5k.
`arunapb/nutriingredientnet-v5`	RGB-D (+depth pred.)	Per-składnik + makro; MAE kcal ∼79,7; wymaga geometrii zbliżonej do overhead Nutrition5k.
`Doses-AI/boba-0.8b-food-GGUF`	GGUF VLM	Qwen3.5-0.8B LoRA; JSON per-składnik; MAE kcal ∼112; on-device (GGUF).
`ardaocak/llava-1.5-7b-food-calorie-estimator`	LLaVA	Estymacja kalorii w stylu VQA; cięższy, wymaga GPU.

5.2 Klasyfikacja potraw (baseline / pipeline A)

- `onnx-community/swin-finetuned-food101-ONNX` — popularny Swin na Food-101;
- `prithivMLmods/Food-101-93M` — ViT/klasyfikator Food-101;
- `nateraw/vit-base-food101` — klasyczny ViT-B na Food-101;
- `Kaludi/food-category-classification-v2.0` — szersze kategorie żywności.

Te modele **nie** przewidują makro bezpośrednio — trzeba dociągnąć bazę odżywczą i model porcji.

5.3 Modele tekstowe / pomocnicze

Na HF jest też sporo LoRA do LLM (SmolLM2, Phi-4, Llama-3, Gemma) uczących się mapować opis jedzenia → wartości odżywcze (np. rodzina `punkt2/foodcalculator-nutrition-*`). Przydatne, gdy najpierw VLM opisze talerz tekstem.

5.4 Jak szybko zacząć na HF

1. Demo / Space: CalorieCLIP lub NutriVision (jeśli dostępny Space).
2. Lokalnie: `transformers` + `opencal-base` (ONNX) albo własna głowica regresji na ViT/ResNet pretrained.
3. Trening: Nutrition5k subset + multitask MSE/Huber na 5 wyjściach.

6 Rozwiązania komercyjne i produktowe

Rynek aplikacji "zrób zdjęcie posiłku" jest dojrzały produktowo, ale dokładność bywa mocno marketingowa.

- **MyFitnessPal** — ogromna baza produktów; Meal Scan (AI photo) jako dodatek do klasycznego logowania / kodów kreskowych.
- **Foodvisor** — rozpoznawanie ze zdjęcia + makro/mikro; mocna pozycja w Europie.
- **SnapCalorie / Cal AI / podobne** — photo-first calorie trackery; niezależne benchmarki 2026 pokazują dużą rozpiętość MAPE między aplikacjami; dania mieszane są najtrudniejsze.
- **Cronometer / MacroFactor** — często wygrywają dokładnością przy workflow manual + barcode (nie czyste photo-AI).

Wniosek: aplikacje konsumenckie łączą CV z ogromnymi bazami i UX (korekta użytkownika). Sam model ze zdjęcia rzadko jest wystarczająco dokładny bez weryfikacji.

7 Metryki ewaluacji

Standardowo raportuje się osobno dla kalorii, masy i każdego makro:

- MAE / RMSE (jednostki bezwzględne: kcal, g),
- MAPE / PMAE (błąd względny w %),
- czasem korelację Pearsona / Bland–Altman.

Przy multitasku warto podawać też średnią po 5 celach oraz unikać porównań między papierami bez tego samego splitu i tej samej curation etykiet.

8 Wyzwania i ograniczenia

1. **Porcja z 2D** — największe źródło błędu; depth / referencja (karta kredytowa, sztućce) pomaga.
2. **Domain shift** — model z kantyny Google ≠ domowa kuchnia polska.
3. **Dania złożone** — sałatki, dania jajeczne, śniadania zachodnie są systematycznie trudne.
4. **Gęste kalorycznie, małe objętościowo** — orzechy, oleje: modele często niedoszacowują.
5. **Baza odżywcza** — zmiana USDA ↔ krajowe tabele zmienia ground truth.
6. **VLM mode collapse** — lokalne VLM bywają gorsze od małej regresji CLIP (jak w CalorieCLIP).

9 Propozycja realizacji projektu (dla grupy)

Cel projektu: system przyjmujący zdjęcie posiłku i zwracający szacunki **kalorii + białka + tłuszczu + węglowodanów** (opcjonalnie masa).

9.1 MVP (realistyczny zakres proseminarium)

1. Baseline klasyfikacji Food-101 (gotowy model HF) + prosta tabela kcal/makro.
2. Regresja multitask na (subsecie) Nutrition5k: backbone ViT-B/16 lub ResNet-50 + 5 głowic.
3. Porównanie z gotowym modelem HF (CalorieCLIP na kcal; NutriVision / OpenCal na makro jeśli uda się odpalić).
4. Prosty interfejs: notebook lub mała aplikacja (Streamlit / Gradio).
5. Raport błędów + analiza fal (np. dania jedno- vs wieloskładnikowe).

9.2 Rozszerzenia (jeśli zostanie czas)

- estymacja depth z RGB i fusion kanałów;
- segmentacja jedzenia vs tło;
- VLM + RAG do USDA / Open Food Facts;
- test na własnych zdjęciach kuchni polskiej + ręczna annotacja.

9.3 Stack technologiczny (propozycja)

Python, PyTorch, Hugging Face `transformers` / `timm`, opcjonalnie ONNX Runtime, Gradio; metryki: MAE, MAPE.

10 Podsumowanie

Estymacja makroskładników ze zdjęcia to aktywna dziedzina na styku computer vision i nutrition informatics. Najważniejszy naukowy grunt to **Nutrition5k** i regresja multitask (CNN/ViT). Na Hugging Face dostępne są zarówno lekkie regresory (CalorieCLIP), jak i VLM produkujące JSON ze składnikami i makro (OpenCal, Boba). Komercyjnie dominują aplikacje łączące photo-AI z bazami i korektą użytkownika.

Dla grupy Dąbrowski–Zabielski najbardziej sensowna ścieżka to: **Nutrition5k + ViT/ResNet multitask** jako rdzeń naukowy, plus **porównanie z 1–2 modelami z Hugging Face** i krótkim demo.

Wybrane źródła i linki

1. Thames i in., *Nutrition5k: Towards Automatic Nutritional Understanding of Generic Food*, CVPR 2021. https://github.com/google-research-datasets/Nutrition5k
2. NutritionVerse-Direct (2024): https://arxiv.org/abs/2405.07814
3. 2D Prediction... Beyond Nutrition5k, *Nutrients* 2025: https://doi.org/10.3390/nu17132196
4. Swin Transformer nutritional composition, *Frontiers in Nutrition* 2024: https://doi.org/10.3389/fnut.2024.1454466
5. DietAI24, *Communications Medicine* 2025: https://doi.org/10.1038/s43856-025-01159-0
6. HF: https://huggingface.co/opencal/opencal-base
7. HF: https://huggingface.co/jc-builds/CalorieCLIP
8. HF: https://huggingface.co/aman24012/nutrivision-om-igsm
9. HF: https://huggingface.co/arunapb/nutriingredientnet-v5
10. HF: https://huggingface.co/Doses-AI/boba-0.8b-food-GGUF
11. USDA FoodData Central: https://fdc.nal.usda.gov/

Dokument roboczy na potrzeby PROseminarium. Liczby downloadów i karty modeli na Hugging Face należy weryfikować na bieżąco przed finalną prezentacją.